

Inteligencia Artificial Generativa y reproducibilidad científica

Reflexiones desde la experiencia trabajando en el área

Patricia Chandía González

Socióloga & Magíster en Inteligencia Artificial UC

Puntos en tabla

- Crisis de reproducibilidad científica
- Ciencia abierta, principios y relación con la IA
- Ventajas
- Desafíos
- Dilemas éticos - Dilemas técnicos
- Conclusiones
- Referencias

Crisis de reproducibilidad científica

¿Qué pasa cuando la investigación experimental no puede obtener los mismos resultados?

¿Por qué?

- Generación de publicaciones y datos a un ritmo sin precedentes
- Contrastación de evidencia que para la mayoría de los descubrimientos no serán persistentes en el tiempo
- Presión del *publish or perish*, presión por publicación más que por el rigor

How Many Scientists Fabricate and Falsify Research? A Systematic Review and Meta-Analysis of Survey Data

Daniele Fanelli*

INNOGEN and ISSTI-Institute for the Study of Science, Technology & Innovation, The University of Edinburgh, Edinburgh, United Kingdom

Abstract

The frequency with which scientists fabricate and falsify data, or commit other forms of scientific misconduct is a matter of controversy. Many surveys have asked scientists directly whether they have committed or know of a colleague who committed research misconduct, but their results appeared difficult to compare and synthesize. This is the first meta-analysis of these surveys. To standardize outcomes, the number of respondents who recalled at least one incident of misconduct was calculated for each question, and the analysis was limited to behaviours that distort scientific knowledge: fabrication, falsification, "cooking" of data, etc.... Survey questions on plagiarism and other forms of professional misconduct were excluded. The final sample consisted of 21 surveys that were included in the systematic review, and 18 in the meta-analysis. A pooled weighted average of 1.97% (N = 7, 95%CI: 0.86–4.45) of scientists admitted to have fabricated, falsified or modified data or results at least once—a serious form of misconduct by any standard—and up to 33.7% admitted other questionable research practices. In surveys asking about the behaviour of colleagues, admission rates were 14.12% (N = 12, 95% CI: 9.91–19.72) for falsification, and up to 72% for other questionable research practices. Meta-regression showed that self reports surveys, surveys using the words "falsification" or "fabrication", and mailed surveys yielded lower percentages of misconduct. When these factors were controlled for, misconduct was reported more frequently by medical/pharmacological researchers than others. Considering that these surveys ask sensitive questions and have other limitations, it appears likely that this is a conservative estimate of the true prevalence of scientific misconduct.

Citation: Fanelli D (2009) How Many Scientists Fabricate and Falsify Research? A Systematic Review and Meta-Analysis of Survey Data. PLoS ONE 4(5): e5738. doi:10.1371/journal.pone.0005738

Editor: Tom Tregenza, University of Exeter, United Kingdom

Received: January 6, 2009; **Accepted:** April 19, 2009; **Published:** May 29, 2009

Copyright: © 2009 Fanelli. This is an open-access article distributed under the terms of the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original author and source are credited.

Funding: The author is supported by a Marie Curie Intra European Fellowship (Grant Agreement Number PIEF-GA-2008-221441). The funders had no role in study design, data collection and analysis, decision to publish, or preparation of the manuscript.

Competing Interests: The author has declared that no competing interests exist.

* E-mail: dfanelli@staffmail.ed.ac.uk

nature

Explore content ▾

About the journal ▾

Publish with us ▾

Subscribe

[nature](#) > [news feature](#) > [article](#)

News Feature | Published: 25 May 2016

1,500 scientists lift the lid on reproducibility

[Monya Baker](#)

[Nature](#) 533, 452–454 (2016) | [Cite this article](#)

273k Accesses | 3233 Citations | 5240 Altmetric | [Metrics](#)

 This article has been [updated](#)

F. Daniele (2009). How Many Scientists Fabricate and Falsify Research? A Systematic Review and Meta-Analysis of Survey Data.

<https://doi.org/10.1371/journal.pone.0005738>

Baker, M. 1,500 scientists lift the lid on reproducibility. *Nature* 533, 452–454 (2016). <https://doi.org/10.1038/533452a>

Y la ciencia abierta

Pero hoy, ha entrado un nuevo actor al laboratorio o al espacio de investigación:
la Inteligencia Artificial Generativa.

¿Qué usos y hasta qué nivel de asistencia de la inteligencia artificial generativa podemos considerar éticos en el trabajo científico?

¿Somos conscientes de la responsabilidad que tenemos al hacer uso de estas herramientas?

Redacción

Análisis de datos

Creación de código

Revisión de literatura

Por un lado, las ventajas

La IA como facilitadora de la apertura

- **Baja la barrera del código:** Optimización de recursos computacionales, documentación y control de cambios automatizados, con supervisión humana experta.
- **Documentación automatizada:** Datos con linaje y documentación de las transformaciones que han sufrido. Gobernanza de datos aumentada.
- **Revisión de literatura exhaustiva:** Herramientas especializadas como Storm de Stanford o Scopus AI (disponible para la comunidad UC), permiten agilizar la revisión del estado del arte.


Por otro lado, los desafíos

1. La alucinación y la fabricación plausible
2. La reproducibilidad de la herramienta
3. El sesgo amplificado.

Por otro lado, los desafíos

1. La alucinación y la fabricación plausible

No son una fuente de verdad en sí mismos, sino que buscan la probabilidad y su sistema de recompensa es siempre dar una respuesta. Hemos visto casos de modelos inventando referencias bibliográficas completas y escándalos por datos inventados por consultoras usando IA.



On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

ABSTRACT

The past 3 years of work in NLP have been characterized by the development and deployment of ever larger language models, especially for English. BERT, its variants, GPT-2/3, and others, most

alone, we have seen the emergence of BERT and its variants [39, 70, 74, 113, 146], GPT-2 [106], T-NLG [112], GPT-3 [25], and most recently Switch-C [43], with institutions seemingly competing to produce ever larger LMs. While investigating properties of LMs and

Técnicas

Gemini puede cometer errores, así que verifica las respuestas.

ChatGPT puede cometer errores. Comprueba la información importante.

Claude es IA y puede cometer errores. Por favor, verifica nuevamente las respuestas.


Usamos RAG (Retrieval Augmented Generation) o aplicaciones como NotebookLM, pero aún así la advertencia continúa.

Es posible que NotebookLM muestre información imprecisa. Verifica las respuestas.

Por otro lado, los desafíos

2. La reproducibilidad de la herramienta

Aún con el mismo prompt, el modelo nos puede entregar resultados distintos. Los LLMs no son deterministas por diseño. A veces la respuesta depende incluso del tráfico de cómputo que están teniendo en el momento.




análisis cuali

Archivo Editar Ver Insertar Formato Datos Herramientas Gemini Extensiones Ayuda

100% 123 Predet...

D27

	A	B	C	D	E	F
	cod_prof	curso	nota	comentario	clasificación	
1						
2	P101	Química	4.5	El contenido es bueno, pero avanza demasiado rápido y cuesta seguir el ritmo si no tienes base previa.	Negativo	
3	P205	Literatura	6.9	Una experiencia inspiradora. Logra que todos participen y se apasionen por las lecturas.	Positivo	
4	P205	Literatura	7	Genera debates muy interesantes en el aula que invitan a la reflexión crítica.	Positivo	
5	P312	Cálculo	5.1	Buenos ejemplos prácticos conectados con la realidad, aunque el material de apoyo visual está desactualizado.	Neutro	
6	P101	Química	6.1	Muy didáctica y paciente. Los ejercicios prácticos ayudaron mucho a entender la lógica.	Positivo	
7	P408	Programación	4	Las evaluaciones no coinciden con lo visto en clases. Falta claridad en los criterios de corrección.	Negativo	
8						
9						
10						
11						
12						
13						
14						
15						
16						
17						
18						
19						
20						
21						
22						



Compartir

Gemini

entrega una columna con cada comentario clasificado en positivo, negativo o neutro

curso	nota	comentario	clasificación	cod_prof	nivel_dificultad
Química	4.5	El contenido es bueno, pero avanza demasiado rápido y cuesta seguir el ritmo si no tienes base previa.	Negativo	P101	Alto
Literatura	6.9	Una experiencia inspiradora. Logra que todos participen y se apasionen por las lecturas.	Positivo	P205	Medio
Literatura	7	Genera debates muy interesantes en el aula que invitan a la reflexión crítica.	Positivo	P205	Medio
Cálculo	5.1	Buenos ejemplos prácticos conectados con la realidad, aunque el material de apoyo visual está desactualizado.	Neutro	P312	Medio
Química	6.1	Muy didáctica y paciente. Los ejercicios prácticos ayudaron mucho a entender la lógica.	Positivo	P101	Bajo
Programación	4	Las evaluaciones no coinciden con lo visto en clases. Falta claridad en los criterios de corrección.	Negativo	P408	Alto

Fuentes (1)

Insertar Copiar

Ejercicio en vivo

Ingresa a tu aplicación o web de IA Generativa de confianza

Utiliza el siguiente prompt:

Completa la siguiente frase y entrega un solo resultado:


Una mujer se vistió de...

¡Comprobemos los resultados!


Por otro lado, los desafíos

3. El sesgo amplificado

Los datos de entrenamiento son los que arrastran los sesgos. Si usamos IA para interpretaciones de resultados, estaremos importando estos sesgos.



"Compassionate manager" by Stable Diffusion.



"Manager" by Stable Diffusion.

El dilema ético y técnico: Caja negra vs. Ciencia abierta

Tenemos una contradicción fundamental. La mayoría de las herramientas de IA comerciales son cajas negras, a lo más conocemos la cantidad de parámetros con los que se entrena cada versión pero no se declara el contenido con el que han sido entrenadas.

- No sabemos el contenido con el que se entrenaron
- No controlamos los pesos de estos contenidos o si hay correcciones
- No hay garantía de continuidad de la versión del modelo

Debemos abogar por el uso de **Modelos Abiertos (Open Weights)** en la ciencia. Modelos que podamos descargar y auditar.

¿Qué estrategias podemos utilizar?

- **Algoritmos auditables:** Huyamos de las cajas negras propietarias que cambian mañana. Usemos modelos abiertos que podamos auditar.
- **Prompt logging:** El prompt es método. Debemos registrarlo y publicarlo con la misma rigurosidad con la que publicamos un cuestionario de encuesta.
- **Historial de datos:** Control de versiones para nuestros datasets.
- **Linaje:** Si una IA tocó el dato, debe quedar una huella digital (linaje) de esa transformación.
- **Calidad:** Y finalmente, no confíen, verifiquen. Implementen validaciones automatizadas para detectar alucinaciones antes de que lleguen al paper.
- **Human-in-the-loop:** Por diseño establecer flujos de trabajo con puntos de control humano obligatorios.

Conclusiones

La IA puede ayudarnos a construir mejoras en las prácticas de ciencia abierta o puede llenar de contenidos sintéticos el mundo, pero en definitiva es una herramienta y es lo que hacemos con ella.

Consideraciones:

1. **No delegar el pensamiento crítico:** La IA puede escribir el código, pero el humano debe verificar la lógica.
2. **Transparencia radical:** Si usaste IA, declararlo. Comparte los prompts. Comparte la versión del modelo y las instrucciones del prompt.
3. **Alfabetización:** Necesitamos científicos que entiendan no sólo estadística, sino cómo funcionan estos modelos para usarlos responsablemente.

